

qm + OpenViking + pacgate-ai 网关/RAG 集成手册

面向律师事务所技术团队与运维工程师 版本 0.1.0 — 2026-09-04 中文版 (PDF) | 英文版: [qm-openviking-pacgate-handbook.md](#)

1. 手册说明

本手册面向需要部署、运维与理解 **qm (协作工作空间) + OpenViking (长期记忆) + pacgate-ai 网关/RAG (法律元数据与向量检索)** 的技术团队。


它回答三个问题：

- qm 如何与 pacgate-ai 网关/RAG 协同？** —— 架构与数据流
- 每个组件做什么？** —— 功能与职责
- 如何部署与排障？** —— 安装步骤与常见问题

红线：本系统中的所有 AI 输出均为**律师复核前的草稿**，绝不构成最终法律意见，也绝不静默捏造事实。这一原则贯穿全部组件。

2. 系统架构

2.1 数据流



2.2 组件职责

组件	端口	职责	实现
qm portal	8181	前端门户：登录入口，代理到 web-ui/admin	ghcr.io/yc-software/qm/portal
qm web-ui	8182	协作界面：会话、文件、审批	ghcr.io/yc-software/qm/web-ui
qm admin	8183	管理控制台：用户、资源、审计	ghcr.io/yc-software/qm/admin
qm core	8180	协作引擎：运行编排、pi harness、审批	ghcr.io/yc-software/qm/core
qm auth	内部	认证代理（Resend/SMTP 登录链接）	ghcr.io/yc-software/qm/auth
OpenViking	1933	长期记忆：结构化记忆、语义检索	ghcr.io/volcengine/openviking
pacgate-api	8080	法律元数据：案件、文档、工作流、RAG	ghcr.io/jzkk720/pacgate-api:0.1.3 (Rust)
pacgate-nginx	8089	统一入口， /pacgate/ 前缀	nginx:1.27-alpine
Ollama	11434	本地/云路由模型 + embedding	Windows 原生

3. qm：协作工作空间

3.1 它是什么

qm 是 Pacgate-ai 的**协作工作空间**。律师在浏览器中打开它，进行团队配合：共享文件、审批 workflow、分派任务、跟踪审批。它通过 `qm up` 独立运行（无 Docker 镜像），使用 **pi harness** 编排 AI 运行。

3.2 关键技术点

- **无 Docker 镜像**：qm 通过 `deploy/qm-pacgate/` 目录里的 `qm up` 运行。
- **harness**：默认使用 **pi**（`HARNESS=pi`）。pi harness 是**进程内**运行（`src/harness/pi-harness.ts`），无需额外安装。
- **模型**：`PI_MODEL` 指定模型 ID。`glm-5.3-flash:cloud` 是自定义注册项，路由到 Ollama（`http://host.docker.internal:11434/v1`）。

3.3 模型配置（qm.config.jsonc）

```
"env": {
  "core": {
    "HARNESS": "pi",
    "SANDBOX_BACKEND": "local",
    "MODEL_BASE_URL": "http://host.docker.internal:11434/v1",
    "PI_MODEL": "glm-5.3-flash:cloud",
    "PI_DETECT_MODEL": "glm-5.3-flash:cloud",
    "PI_TITLE_MODEL": "glm-5.3-flash:cloud",
    "PI_JUDGE_MODEL": "glm-5.3-flash:cloud",
    "NODE_ENV": "development"
  }
}
```

为什么设置 PI_DETECT/TITLE/JUDGE_MODEL: qm 的辅助模型调用（安全屏、标题、判断）默认解析到 gpt-5.6-luna（provider=openai），会打到真实 api.openai.com 并用假密钥 ollama-local 触发 401。设置这三个变量为 glm-5.3-flash:cloud 后，辅助调用路由到 Ollama。

3.4 沙箱与工具

qm 的沙箱层（sandbox/）暴露两个工具给 AI：

工具	说明
pacgate-qm	Pacgate 工作流发现、案件绑定、案件记忆、工作流执行
firecrawl-qm	网页抓取与内容提取

pacgate-qm CLI 支持的命令：

```
workflow-categories workflows workflow ensure-matter
memory-get memory-save execute-workflow
ov-remember ov-search ov-read
```

3.5 与 OpenViking 集成

qm 沙箱通过 pacgate-qm 的 ov-remember / ov-search / ov-read 命令访问 OpenViking 长期记忆：

- ov-remember --content "<事实>"：存储持久记忆（异步提取为结构化记忆）
- ov-search --query "<语义查询>"：回忆相关记忆、资源与技能
- ov-read --uri "viking://user/default/memories/<path>"：读取具体记忆文档

红线：绝不通过 `ov-remember` 存储案件文件或保密案件材料——那些属于 Pacgate 案件存储。OpenViking 记忆仅用于会话上下文：决策、偏好与工作知识。

4. OpenViking：长期记忆通道

4.1 它是什么

OpenViking 是 Pacgate-ai 的**长期记忆**服务，把跨会话的决策、偏好与工作知识提取为结构化记忆，供 AI 在后续会话中语义检索、回忆与复用。

4.2 配置

```
{
  "server": { "host": "0.0.0.0", "port": 1933, "root_api_key": "<OPENVIKING_ROOT_API_KEY>" },
  "storage": { "workspace": "/app/.openviking/workspace" },
  "embedding": {
    "dense": {
      "provider": "ollama",
      "api_base": "http://host.docker.internal:11434/v1",
      "model": "nomic-embed-text",
      "dimension": 768
    }
  }
}
```

4.3 关键点

- **端口：** 1933 (HTTP, 对外暴露)
- **embedding：** Ollama 的 `nomic-embed-text` (768 维)
- **root_api_key：** ⚠ 使用 `OPENVIKING_ROOT_API_KEY`，**不是** `OPENVIKING_API_KEY`。

5. pacgate-ai 网关 / RAG (pacgate-api)

5.1 它是什么

pacgate-api 是 Pacgate-ai 的**法律元数据网关** (Rust 实现)，管理租户、案件、文档、 workflow 模板，并提供 RAG (向量检索) 与法律连接器检索。

5.2 服务表面

服务	端点	说明
认证	POST /api/auth/login	登录并返回 JWT
案件	GET /api/matters	列出案件
文档	GET /api/matters/:id/documents	某案件的文档
工作流	GET /api/workflows	列出工作流模板
工作流分类	GET /api/workflow-categories	工作流分类
工作流详情	GET /api/workflows/:id	单工作流步骤
RAG	GET /api/kb/search	内部按案件向量检索
连接器	GET /api/search	外部法律数据库检索
连接器列表	GET /api/search/connectors	可用法律数据源

5.3 RAG（向量检索）

pacgate-api 的 RAG 存储使用 Ollama 的 `nomic-embed-text` 作为 embedding 模型，支持按案件（`matter_id`）的向量检索，并支持数据分级（`max_data_level`）。这使 AI 能够带引用出处地回答法律问题，而不必上传文件。

5.4 工作流模板

pacgate-api 暴露 10 个法律工作流模板：

分类	工作流	步骤数
contract_review	Contract Review (合同审查)	3
contract_review	Contract Comparison (合同比对)	2
due_diligence	Due Diligence Review (尽调审查)	3
legal_research	Legal Research Memo (法律检索备忘录)	3
tabular_review	Tabular Document Review (表格化文档审查)	3
document_generation	Contract Drafting (合同起草)	2
document_generation	Legal Opinion (法律意见书)	2
compliance	Compliance Check (合规检查)	3
ma	SPA Review (股权收购协议审查)	3
litigation	Discovery Review (证据开示审查)	3

5.5 pacgate-qm 桥

qm 沙箱中的 `pacgate-qm` CLI 调用 `pacgate-api` (经 `nginx /pacgate/` 前缀)。它用 `PACGATE_API_EMAIL` / `PACGATE_API_PASSWORD` 认证, 支持:

- **工作流发现:** `workflow-categories`、`workflows`、`workflow <id>`
- **案件绑定:** `ensure-matter --org-id <org> --channel-id <channel>`
- **案件记忆:** `memory-get`、`memory-save --memory-json '{"key":"value"}'`
- **工作流执行:** `execute-workflow --workflow-id <id> --org-id <org> --channel-id <channel>`

红线: 绝不捏造工作流 ID、案件 ID 或 Pacgate 作用域绑定。先查询, 或提供真实的 QM 作用域标识符。

6. 部署

6.1 前置条件

- Docker Desktop (WSL2 后端)
- Ollama (Windows 原生) 已拉取 `glm-5.3-flash:cloud`、`nomic-embed-text` 等模型
- Node.js 24+ (供 qm 使用)
- `deploy/qm-pacgate/` 目录与 `qm.config.jsonc`

6.2 qm 部署

```
cd deploy/qm-pacgate
npm ci                # 或 npm install
npm exec qm -- check  # 必须通过
npm exec qm -- sandbox build # 必须成功构建沙箱镜像
npm exec qm -- up      # 启动（会重建所有服务容器）
```

⚠ **qm up 是破坏性的**：它会 `docker rm -f` 所有服务并重新运行，注入 `.env` 中的密钥。这会把两处**手工修复**还原：1. `pi-models.ts` 的 `glm-5.3-flash:cloud` 条目（在容器可写层），需 `docker cp` 重新应用。2. `dev` 模式认证（若设置了 `CORE_SIGNING_SECRET` 会强制 `portal` 模式，登录失效）。

6.3 验证

```
# 所有服务运行
docker ps | Select-String 'qm-pacgate'

# 健康检查（核心）
docker logs qm-pacgate-core --since 5m | Select-String 'listening'

# pacgate-api 工作流（经 nginx）
$env:PACGATE_API_URL='http://localhost:8089/pacgate'
$env:PACGATE_API_EMAIL='qm-bridge@pacgate.local'
$env:PACGATE_API_PASSWORD='<password>'
python deploy/qm-pacgate/sandbox/tools/pacgate-qm/pacgate_qm.py workflow-categories
```

7. 排障（常见问题）

7.1 登录：portal 显示 "This deployment isn't set up yet"

症状：portal 显示“未设置”，无法进入管理控制台。**根因**：core 的 `modelProviderConfigured:false`；且 `admin_grants` 表为空，无人是 admin，`/admin` 403。**修复**：向 `admin_grants` 表种入管理员：

```
docker exec qm-pacgate-pg psql -U postgres -d qm -c "INSERT INTO admin_grants (principal_id, s
```

7.2 登录：魔链 "This sign-in link no longer works"

症状：打开邮箱里的登录链接报“链接失效”。**根因：**魔链是**单次使用且绑定浏览器**——JWT `st` 声明必须匹配发起流程的浏览器 OAuth `state` cookie。在另一个浏览器/配置文件打开或重复使用已用过的链接会报错。**修复：**在发起登录的**同一个浏览器**中打开链接，点击确认。

7.3 模型 401 "Incorrect API key"

症状：`ollama-local` 被当作真实 API 密钥，请求打到真实 `api.openai.com`。**根因：**辅助模型解析到 `gpt-5.6-luna` (`provider=openai`)，或主模型选成 `gpt-5.6-sol`。**修复：**- 设置 `PI_DETECT_MODEL / PI_TITLE_MODEL / PI_JUDGE_MODEL = glm-5.3-flash:cloud` (辅助调用) - 通过管理 API 将 org 基础模型设为 `glm-5.3-flash:cloud`：

```
PUT /admin/api/scopes/org:pacgate/base-model body: {"modelId":"glm-5.3-flash:cloud"}
```

7.4 沙箱：报 "requires a running Docker daemon"

症状：`SANDBOX_BACKEND=local` 时报“需要运行中的 Docker daemon (是否在运行 Docker Desktop?)”，但 Docker 明明在运行。**根因：**`SANDBOX_BACKEND=local` 让 `qm` core 在**容器内部**运行 `docker` CLI。但 `qm` 的 `docker` 后端**不挂载** `docker.sock`，且 `core` 镜像是 Alpine，**没有** `docker` 二进制。所以 `preflight` 必然失败 (错误信息具有误导性)。**修复：**需要给 `core` 挂载 `docker.sock` 并安装 `docker` CLI，或切换后端 (`sprites / aws`)。目前未接线。

7.5 沙箱镜像不存在

症状：`local sandbox image ... not found`。**根因：**配置中固定的镜像 `localhost:5000/pacgate-sandboxes@sha256: ...` 本地不存在，`localhost:5000` registry 不可达。**修复：**`npm exec qm -- sandbox build` (构建 `pacgate-sandbox:local`)，或修正配置中的镜像 `pin`。

8. 安全与隐私

- **数据边界：**案件文件、检索历史保存在本机 AI 计算机上；对话文本经由已启用的 AI 模型服务处理，文件本身**绝不**上传。
- **凭据：**`PACGATE_API_EMAIL / PACGATE_API_PASSWORD`、`OPENVIKING_ROOT_API_KEY` 等存于 `.env` (gitignored)。**不要**提交到仓库。
- **红线：**AI 输出均为律师复核前的草稿，绝不构成最终法律意见。