

Pacgate AI - 双 AIPC 部署手册

在每台机器上克隆仓库，运行相同的安装步骤，两台机器即可完全运行 deer-flow 研究与 qm 协作。
 版本 0.1.23 - 2026-10-05 英文版本：[AIPC-DEPLOYMENT-HANDBOOK.md](#) 前置条件：Docker
 Desktop、Ollama、Node.js 24+。install.ps1 会拉取 ollama-models.txt 中列出的模型。

⚠ 重要发现（2026-09-02）— 部署 AIPC #2 前请先阅读

以下问题是在 AIPC #1 试点期间发现的，已在本仓库中修复。AIPC #2 必须拉取更新后的代码（见 Stage 1），以获得这些修复。

2026-09-23 更新（取代 2026-09-15 的「两者均可克隆」提示）。两个仓库已不再一致——
 pacgate-ai/pacgate-ai-pr 落后 26 个提交，缺少 workflow 接线修复（b7fc540、
 039afdc），克隆 fork 会得到 10 个内置工作流，而不是公司的 222 个，且不会报错。请克隆
 JZKK720/pacgate-ai-pr（见 Stage 1）。向哪个仓库推送发布标签，仍决定 镜像进入哪个 GHCR
 命名空间——见 plans/012-master-release-namespace.md。

1. deer-flow 代理无法查询 pacgate 的法律数据库。根本原因：没有工具接入 pacgate-api 的
 /api/kb/search (RAG) 或 /api/search (法律连接器)，且
 记忆适配器静默回退到本地文件 (PacgateMemoryStorage 需要 PACGATE_MATTER_ID)。修复：
 新增 pacgate-mcp 服务 (FastMCP)，向 deer-flow 暴露
 pacgate_kb_search、pacgate_connector_search、pacgate_list_connectors。已在
 deer-flow-extensions-config.json 中与 openviking 并列注册。
2. openviking MCP 内置了错误的 API 密钥。deer-flow-extensions-config.json
 使用了应用密钥 (OPENVIKING_API_KEY)，但 openviking 的 root_api_key 是
 OPENVIKING_ROOT_API_KEY。错误的密钥导致 openviking 返回 401，进而回滚了整个 MCP
 工具加载 (deer-flow 使用 asyncio.gather)，因此没有任何 MCP 工具出现。修复：使用
 OPENVIKING_ROOT_API_KEY（模板现已使用 \${OPENVIKING_ROOT_API_KEY}）。
3. docker compose up -d --force-recreate deer-flow 会清空 deer-flow 的本地数据库。
 SQLite 数据库、管理员用户、线程和 .jwt_secret 位于 /app/backend/.deer-flow/
 容器内部（未挂载）。重建容器会丢失它们 → 前端返回 401 并出现 /setup 页面。配置变更请使用
 docker compose restart deer-flow；只有在你接受丢失本地 数据库时才重建（然后重新运行
 /setup）。
4. QM 登录需要邮件传输，而不是 Outlook SMTP。旧的 SMTP 路径 (smtp.office365.com +
 应用密码) 已失效——微软已于 2025 年 9 月停用 Exchange Online 的基本身份验证 / 应用密码。qm
 check 失败并返回 535 5.7.139 Authentication unsuccessful。修复：qm 的 auth
 代理现在使用 Resend 传输 (AUTH_EMAIL_TRANSPORT=resend)。你必须在
 deploy/qm-pacgate/.env 中提供 RESEND_API_KEY（见 Stage 4）。此条最初称 Resend
 是唯一选项，Stage 4 的双传输设置已取代——试点用 Mailpit，无需密钥。
5. qm web-ui 无法自行认证。其服务器 (/app/server/index.ts) 设置 AUTH_MODE =
 COOKIE_AUTH ? "dev" : "portal"。因为设置了 CORE_SIGNING_SECRET，它处于 portal
 模式，需要 portal 签发的身份令牌。没有无需密钥的方式直接访问 web-ui——你必须运行
 portal+auth (Resend) 或外部 OIDC 提供方。ADMIN_GRANTS 是授权种子，不是登录方式。
6. pacgate-ai 账号向 JZKK720/pacgate-ai-pr 推送被阻止 (403，需要 2FA 授权)。变通方案：
 pacgate-ai 账号可以创建 fork 并推送到那里。fork pacgate-ai/pacgate-ai-pr 现在在 main
 上携带所有修复。

架构：两台相同的机器

两台 AIPC 都运行完整的栈：

```

██ AIPC ███
  nginx :8089  -> pacgate-api :8080██ Rust ███ API██
                -> deer-flow :8001██████████
Postgres :5432██████████████
OpenViking :1933██████████ MCP██
qm :8182██████████ `qm up` ███
Ollama :11434██████ GPU/NPU██

```

每台机器都是自包含且独立可运行的。任一机器上的律师都可以使用研究模式（deer-flow，位于 <http://localhost:8089/research/>）和协作模式（qm，位于 <http://localhost:8182>），无需依赖另一台机器。

如果之后希望在两台机器之间共享事项数据，请用私有网格（Tailscale 或 WireGuard）连接它们，并决定同步或单一权威模型。这是试点后的决策，不是部署前置条件。

开始前需要准备什么

- 源码仓库访问权限——JZKK720/pacgate-ai-pr 或 pacgate-ai/pacgate-ai-pr 均可。两者均为公开，单纯克隆无需任何认证；仅当需要推送时才需 PAT 或 `gh auth login`。
- 两台 AIPC 上都运行 Docker Desktop
- 两台 AIPC 上都运行 Ollama（`install.ps1` 会拉取它需要的模型）
- 如果使用带 cloud 标签的 deepseek 模型，每台 AIPC 上完成 `ollama signin`
- 两台 AIPC 上都安装 Node.js 24+（供 qm 使用）
- 无需 `docker login ghcr.io`——Pacgate 运行时镜像以公开 GHCR 包发布（见 Stage 0）。

Stage 0：运行时镜像（开发机，已完成）

运行时已发布到 GHCR, AIPC 上无需重建。

当前版本（应拉取的版本）：

镜像	状态
ghcr.io/jzkk720/pacgate-api:0.1.23	已发布，公开。新增案件工作区汇总视图（GET /api/matters/:id/workspace）。
ghcr.io/jzkk720/pacgate-mcp:0.1.23	已发布，公开。向 deer-flow 暴露 19 个 MCP 工具（新增 pacgate_get_workspace、pacgate_read_memory、pacgate_write_memory）。
ghcr.io/jzkk720/deer-flow-pacgate:0.1.23	已发布，公开。
ghcr.io/jzkk720/deer-flow-frontend-pacgate:0.1.23	已发布，公开。
ghcr.io/jzkk720/ocr-service:0.1.23	已发布，公开。PaddleOCR 抽取服务；自 0.1.16 起为一等镜像。
ghcr.io/volcengine/openviking@sha256:46f9e34c...	在 compose.prod.yaml 中按摘要固定。上游公开镜像。

命名空间与版本于 2026-09-22 更正。此表此前列出 `ghcr.io/pacgate-ai/*` 的 0.1.0/0.1.3。pacgate-ai 为遗留镜像，实际命名空间为 `jzkk720`，发布自 plan 016

起已迁移。旧表中的 `pacgate-ai/...-frontend-pacgate:0.1.0` 行标注“已发布”，实际返回 404——从未存在。五个 `jzkk720/*` 镜像按当前固定值（0.1.23，见上表）匿名拉取均返回 HTTP 200。

历史发布表（保留以追溯，已被取代）：

镜像	状态
ghcr.io/pacgate-ai/pacgate-api:0.1.3	当时已发布。修复 0.1.1 的容器网络 bug。
ghcr.io/pacgate-ai/pacgate-mcp:0.1.3	当时已发布。
ghcr.io/pacgate-ai/deer-flow-pacgate:0.1.3	当时已发布。
ghcr.io/pacgate-ai/deer-flow-frontend-pacgate:0.1.0	从未发布——返回 404。请勿使用。

所有 Pacgate 包必须在 GHCR 上设置为公开可见，以便 AIPC 无需注册凭据即可拉取。上线前验证：

```
# docker login HTTP 200 401/403
# 404 compose.prod.yaml
#
#
# Accept 404 200
#
# compose.prod.yaml
#
$acc = "application/vnd.oci.image.index.v1+json,application/vnd.docker.distribution.manifest.list.v2+json,ap
$compose = "deploy/client-bundle/compose.prod.yaml"
$pins = Select-String -Path $compose -Pattern "image:\s*(ghcr\.io/[\s]+)" -AllMatches |
    ForEach-Object { $_.Matches } | ForEach-Object { $_.Groups[1].Value } |
    Where-Object { $_ -notmatch "openviking" } | Sort-Object -Unique

foreach ($pin in $pins) {
    $repo = $pin -replace "ghcr\.io/", "" # owner/name:tag
    $name = ($repo -split ":")[0] # owner/name
    $tag = ($repo -split ":")[1]
    $t = (Invoke-RestMethod "https://ghcr.io/token?scope=repository:$name:pull").token
    $code = (Invoke-WebRequest -Uri "https://ghcr.io/v2/$name/manifests/$tag" `
        -Headers @{Authorization="Bearer $t"; Accept=$acc} `
        -Method Head -UseBasicParsing).StatusCode
    "{0,-58} => HTTP {1}" -f $pin, $code
}
```

切换可见性（GitHub Web UI——个人账户的 API 路由返回 404）：GitHub → 你的个人资料 → Packages → **pacgate-api** → Package settings → Visibility → Public → Save。对 **deer-flow-pacgate** 重复此操作。这是安全的：镜像只包含编译后的二进制文件和 SQL 迁移，所有密钥都在运行时通过 `.env` 注入，且安装程序已拥有对相同代码的完整源码访问权限。

仅当 Rust 源码变更时，才在开发机上重建并推送。标签值应从 compose 固定值中读取，而不要手写版本号——此处硬编码的标签已两次过期，其中一次还把健康系统误报为故障：

```
cd c:\Users\cubeccloud-io\github-pr\pacgate-ai-pr
# jzkk720 'pacgate-ai/pacgate-api'
# compose.prod.yaml $tag
#
$tag = (Select-String -Path deploy/client-bundle/compose.prod.yaml `
    -Pattern 'jzkk720/pacgate-api:(\S+)').Matches.Groups[1].Value
if (-not $tag) { throw 'could not read the image tag from compose.prod.yaml' }
docker build -t ghcr.io/jzkk720/pacgate-api:$tag -f pacgate-ai/Dockerfile ./pacgate-ai
docker push ghcr.io/jzkk720/pacgate-api:$tag
```

实践中建议使用 `build-ghcr.yml` 工作流，以保证四个镜像版本一致——参见 `deploy/README-BUILD.md` 与 `plans/012-master-release-namespace.md`。

不要在 AIPC 上重建——试点运行已发布的摘要。

端口说明： 栈将 `nginx` 绑定到主机端口 `8089` (`deploy/client-bundle/compose.prod.yaml` 中提交的值)。如果该端口在机器上已被占用， 请编辑 `deploy/client-bundle/compose.prod.yaml` 中 `nginx` 的 `ports:` 条目， 并在下方所有验证 URL 中使用新端口。

Stage 1：在每台 AIPC 上克隆仓库

在两台机器上：

```
cd C:\
git clone https://github.com/JZKK720/pacgate-ai-pr.git
cd pacgate-ai-pr
git remote -v # origin JZKK720/pacgate-ai-pr
```

AIPC #2 说明 (2026-09-23 更正) : 两个仓库已不再一致, 因此「克隆哪一个都可以」不再成立。请克隆 JZKK720。

pacgate-ai/pacgate-ai-pr 落后 26 个提交（2026-09-23 核实），缺少 b7fc540 与 039afdc，因此仍带有最初的 workflow 接线缺陷。fork 中虽有那 15 个 workflow YAML，但未接入 pacgate-api，于是 API 只会提供 10 个内置工作流，而不是公司的 222 个，而且不会报任何错。上面「内容完全一致」的说法在写入时是准确的，分歧发生在之后——这正是文档不应在没有可失败检查的情况下断言两者同步的原因。

命名空间方面的差异没有变化：向哪个仓库推送标签，决定镜像发布到哪个 GHCR 命名空间。见

仓库为公开，克隆无需凭据；仅当需要推送时才使用个人访问令牌或 GitHub CLI (`gh auth login`)。

Stage 2：部署核心栈（两台机器，步骤相同）

在每台 AIPC 上运行这些步骤。Docker Compose 栈会启动 pacgate-api、Postgres、nginx 和 deer-flow。

```
cd C:\pacgate-ai-pr\deploy\client-bundle
copy .env.example .env
notepad .env
```

填写这些值：

[illegible]

OPENVIKING_API_KEY 是必需的——安装程序会用它渲染 deer-flow-extensions-config.json, 如果缺失或保留为 change-me 则报错停止。

如果需要，生成密钥：

```
# ■■■■■■16 ■■■■■■
-join ((1..16) | ForEach-Object { '{0:x}' -f (Get-Random -Maximum 16) })

# JWT ■■■32 ■■■■■■
-join ((1..32) | ForEach-Object { '{0:x}' -f (Get-Random -Maximum 16) })

# OpenViking ■■■■■ 32 ■■■■■■——■■■■■■■■■■
-join ((1..32) | ForEach-Object { '{0:x}' -f (Get-Random -Maximum 16) })
```

运行安装程序：

```
.\install.ps1
```

安装程序会拉取（公开、无需登录的）GHCR 镜像，从 `.env` 密钥渲染 `OPENVIKING_CONF_CONTENT` 和 `deer-flow-extensions-config.json`，启动 Docker Compose 栈，并拉取 `ollama-models.txt`

中列出的 Ollama 模型。如果模型已拉取，此步骤很快。

验证核心栈：

```
docker compose -f compose.prod.yaml ps
curl http://localhost:8089/version
curl http://localhost:8089/pacgate/health
```

预期：八个容器全部运行（pacgate-db、pacgate-api、deer-flow、deer-flow-frontend、pacgate-mcp、ocr-service、openviking、nginx），`/version` 返回 `{"version":"0.1.23","revision":"<git sha>"}`，且 `/pacgate/health` 返回 `ok`。

不要在 nginx 根路径探测 `/health`。nginx 按设计将 `/` 路由到 deer-flow 前端，`curl http://localhost:8089/health` 会返回前端的 404 页面——看似失败，实为正确路由。`/version` 也在根路径（映射到 API 的 `/build-info`）；只有 `/pacgate/*` 路径会到达 API。

Stage 3：初始化租户并开通账号（两台机器）

`install.ps1` 现已自动完成（step 6a）。在新版安装上无需手工执行，本节保留用于恢复场景，其中的命令与安装程序实际运行的命令一致。

自 0.1.22 起的账号机制（开通人员前请先阅读）

- `POST /api/auth/register` 仅限首位用户：在全新部署上只创建一个账号（引导管理员），此后一律返回 403。
- 此后的每个账号由管理员通过 `POST /api/auth/users` 创建（Bearer = 管理员令牌）。
- 检索工作区登录 = 邮箱 + 密码；协作（qm）登录 = 一次性邮件链接，受 `AUTH_ALLOWED_EMAILS` 名单控制。

先初始化租户，再由安装程序引导创建管理员：

```
# ■■■■■■■■■■slug ■■■■ PACGATE_TENANT_ID ■■■■
docker exec pacgate-db psql -U pacgate -d pacgate -c "INSERT INTO tenants (name, slug) SELECT 'Default Firm'";
```

开通律师账号（管理员账号存在后执行）：

```
$login = Invoke-RestMethod -Uri "http://localhost:8089/pacgate/api/auth/login" -Method Post `
    -Body '{"email":"admin@pacgate-law.com","password":"<admin-password>"}' `
    -ContentType "application/json"
$body = @{"email":"<attorney-email>"; password="<attorney-password>"; role="attorney"} | ConvertTo-Json
Invoke-RestMethod -Uri "http://localhost:8089/pacgate/api/auth/users" -Method Post `
    -Headers @{Authorization="Bearer $($login.token)"} -Body $body -ContentType "application/json"
```

注册 qm 桥接服务账号（安装程序自动完成，此处保留手工方式用于恢复），使用相同的管理员开通路由：`email="qm-bridge@pacgate-law.com"`。

协作工作区侧：在 `deploy/client-bundle/qm-pacgate/.env` 中设置 `AUTH_ALLOWED_EMAILS`（逗号分隔）与 `ADMIN_GRANTS=<email>:org_admin`，然后重新运行 `setup-qm.ps1`。

Stage 3.5：验证 OpenViking 记忆服务（两台机器）

OpenViking 是长期记忆通道：deer-flow 和 qm 在那里存储对话上下文，并在后续会话中召回。它作为 compose 栈的一部分启动。

```
curl http://localhost:1933/health
```

预期：`{"status":"ok","healthy":true,...}`。安装程序将 OpenViking 配置（Ollama 嵌入 + VLM）渲染到 `.env` 中的 `OPENVIKING_CONF_CONTENT`，并在首次启动时初始化服务器的 `ov.conf`。

功能检查（可选，使用 `.env` 中的根密钥）：

```
$key = (Get-Content .env | Select-String '^OPENVIKING_ROOT_API_KEY=').Line.Split('=')[1]
$body = '{"jsonrpc":"2.0","id":1,"method":"tools/list"}'
curl.exe -s -X POST http://localhost:1933/mcp -H "X-API-Key: $key" -H "Content-Type: application/json" -H "A
```

预期：工具列表包含 find、search、read、remember。

边界规则：OpenViking 只存储对话上下文（决策、偏好、工作知识）。事项文档和 T1-T4 受控内容保留在 pacgate-api/pacgate-rag 中。

Stage 4：引导 qm（两台机器，步骤相同）

qm 独立于 Docker Compose 栈运行。在核心栈健康后，在每台机器上引导它。

```
cd C:\pacgate-ai-pr\deploy\client-bundle
.\setup-qm.ps1
```

脚本会提示输入：- 管理员工作邮箱（小写）- Pacgate 桥接邮箱：`qm-bridge@pacgate.local` - Pacgate 桥接密码：你在 Stage 3 中注册的那个

脚本会生成签名密钥，在 `qm-pacgate` 目录中创建 `.env`，用 `qm check` 验证配置，并用 `qm sandbox build` 构建沙箱镜像。

QM 登录需要邮件传输。qm 的 auth 代理发送一次性登录链接。支持两种传输：

- 本地/试点拓扑（Mailpit SMTP 捕获器）：`SMTP_HOST=mailpit SMTP_PORT=1025 AUTH_EMAIL_TRANSPORT=smtp SMTP_TLS=none`。链接落在 Mailpit 收件箱中——试点时 打开 <http://localhost:8025> 领取登录链接即可，不发送真实邮件。
- 生产拓扑（Resend）：`AUTH_EMAIL_TRANSPORT=resend` 并在 `deploy/qm-pacgate/.env` 中设置 `RESEND_API_KEY`，`AUTH_EMAIL_FROM` 使用 Resend 已验证的发件人（Outlook 地址不属于已验证；微软已停用 Exchange Online 的基本身份验证/应用密码，因此原生 Outlook SMTP 不受支持）：

```
RESEND_API_KEY=re_XXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXX
AUTH_EMAIL_FROM="PacGate <onboarding@resend.dev>"
```

要么在 Resend 中验证一个真实域名（例如 `pacgate-law.com`），要么暂时使用 Resend 的测试发件人：

AUTH_EMAIL_FROM="PacGate <onboarding@resend.dev>"

启动 qm :

```
cd C:\pacgate-ai-pr\deploy\qm-pacgate
node_modules\.bin\qm.cmd up
```

注意：`npm exec qm -- up` 可能被 PowerShell 执行策略阻止（`npm.ps1`）。请改用 `node_modules\.bin\qm.cmd up`。

验证 qm :

```
# ■■ http://localhost:8182 (web-ui) - ■■ portal ■■■■  
# ■■ http://localhost:8181 (portal) - ■■■■  
# ■■■■■■■■■■■■■■■■■■■■■■■■■■■■■ Mailpit  
# ■■■■■■■■■■  
# ■■■■"List available pacgate workflows"
```

Web-ui 认证现实：qm web-ui (:8182) 无法自行认证任何人——它必须通过 portal (:8181) 访问，由 portal 签发身份令牌。如果你直接打开 :8182，会看到 "reached through the portal."。始终通过 :8181 访问。

开发模式替代方案（试点/单用户）：对于本地试点，你可以让 qm 以 dev/cookie 模式运行，而不是 portal。用 `NODE_ENV=development + ALLOW_UNAUTHENTICATED_CORE=1` 且不设置 `CORE_SIGNING_SECRET` 重建 qm-pacgate-core，并用不设置 `CORE_SIGNING_SECRET` 重建 qm-pacgate-web-ui。然后 `POST /signin` 直接在 :8182 用 `{"user": "<principal>"}` 工作，且无需 Resend 密钥。这不是生产正确配置（无认证）——仅用于单用户试点。

Stage 5 : 验证 deer-flow (两台机器)

在每台机器上，验证研究工作空间：

```
# █ http://localhost:8089/research/
# ██████████
# ████"Summarize recent force majeure case law in China"
# ██████████
# ██████████████████
```

Stage 5.5：全链路操作 — deer-flow $\leftrightarrow$ QM $\leftrightarrow$ OpenViking

两个工作空间共享一个 OpenViking 长期记忆通道和一个 pacgate-api 元数据存储。本节说明两个系统如何相互通信，以及如何端到端验证该链路。

拓扑 (2026-09-04 已验证)

```
pacgate-ai-bundle_default (Docker Compose)
openviking :1933 ← MCP find/search/read/remember
pacgate-api :8080 ← API / / 
pacgate-mcp :8000 ← FastMCP pacgate KB/
deer-flow :8001 ← openviking + pacgate-mcp
nginx :8089 ← deer-flow + /pacgate/ API

qm-pacgate (qm up)
qm-pacgate-core ← 
qm-pacgate-web-ui ← UI:8182
qm-pacgate-pg ← qm Postgres

qm-pacgate-core pacgate-ai-bundle_default
openviking:1933pacgate-api:8080 host.docker.internal:11434Ollama
```

链路如何工作

1. deer-flow → OpenViking: deer-flow-extensions-config.json 将 openviking 注册为 `http://openviking:1933/mcp` 的 HTTP MCP 服务器，使用根 API 密钥（`OPENVIKING_ROOT_API_KEY`）。研究运行在那里存储和召回对话上下文。
2. deer-flow → pacgate: pacgate-mcp (FastMCP) 向 deer-flow 暴露 `pacgate_kb_search / pacgate_connector_search / pacgate_list_connectors`，由 pacgate-api 的 RAG + 法律连接器支撑。
3. QM → OpenViking: QM 核心有 `OPENVIKING_URL=http://openviking:1933` 和 `OPENVIKING_API_KEY`（根密钥）。pacgate-qm 沙箱工具（`ov-remember / ov-search / ov-read`）在代理沙箱内通过 `http://host.docker.internal:1933` 调用 OpenViking，并带 `OPENVIKING_ACCOUNT=pacgate-law + OPENVIKING_USER`。
4. QM → pacgate: pacgate-qm 沙箱工具登录 pacgate-api（`PACGATE_API_EMAIL / PACGATE_API_PASSWORD`）以发现工作流、将 QM 作用域绑定到事项、读写事项记忆，并执行工作流。

验证全链路

```
# 1. OpenViking MCP ██████ .env ██████
$key = (Get-Content .env | Select-String '^OPENVIKING_ROOT_API_KEY=').Line.Split('=')[1]
```

```
$body = '{"jsonrpc":"2.0","id":1,"method":"tools/list"}'
curl.exe -s -X POST http://localhost:1933/mcp -H "X-API-Key: $key" -H "Content-Type: application/json" -H "A
# ■■■■■ find/search/read/remember

# 2. QM ■■■■■ openviking + pacgate-api + Ollama
docker exec qm-pacgate-core sh -c "curl -s -o /dev/null -w 'openviking:%{http_code}\n' http://openviking:193

# 3. QM ■■■■■ dev/cookie ■■■■
$body = '{"user":"admin@pacgate-law.com"}'
curl.exe -s -X POST http://localhost:8182/signin -H "Content-Type: application/json" -d $body
# ■■■■{"ok":true,"user":"admin@pacgate-law.com"}
```

QM ↔ bundle 网络加入（幂等）

QM 核心已加入 bundle 网络，以便按名称解析 openviking 和 pacgate-api。如果 qm up/qm down 循环丢失了加入，请重新应用：

```
docker network connect pacgate-ai-bundle_default qm-pacgate-core
```

注意：QM 有意不是 bundle 中的 Docker Compose 服务。它由 @yc-software/qm CLI（qm up/qm down）管理，有自己的生命周期。网络加入是唯一的耦合——请保持这样。不要将 QM 重写为 compose 服务；那会与 qm CLI 冲突，并在每次 qm up 时重建容器。

Stage 6：冒烟测试清单（两台机器）

在每台 AIPC 上独立运行此清单。

核心栈

- [] docker compose -f compose.prod.yaml ps 显示 8 个服务运行（含 openviking、pacgate-mcp、ocr-service、deer-flow-frontend）
- [] curl http://localhost:8089/version 返回 0.1.23；curl http://localhost:8089/pacgate/health 返回 ok
- [] curl http://localhost:1933/health 返回健康 JSON
- [] Postgres 有 pacgate-law 租户
- [] 管理员用户可以在 http://localhost:8089/api/auth/login 登录
- [] deer-flow 在 http://localhost:8089/research/ 返回真实研究回复

qm 协作

- [] npm exec qm -- status 显示 qm 运行中
- [] http://localhost:8182 加载 qm Web UI
- [] 管理员可以登录
- [] qm 可以列出 Pacgate 工作流类别
- [] qm 可以通过桥接执行一个 Pacgate 工作流

Ollama

- [] ollama list 显示所需模型
- [] deer-flow 可以调用 Ollama 进行推理
- [] qm 可以调用 Ollama 进行推理

数据

- [] ./data/tenants/ 目录存在且可写
- [] ./openviking/ 目录存在并在重启后持久化
- [] 通过 API 上传文档正常
- [] deer-flow 研究运行后事项记忆持久化
- [] 跨会话召回：通过 OpenViking remember 存储的事实可在后续会话中通过 search 召回

部署后管理栈

启动和停止

```
# ■■■■■■
docker compose -f compose.prod.yaml up -d

# ■■■■■■
docker compose -f compose.prod.yaml down

# ■■ qm
cd C:\pacgate-ai-pr\deploy\qm-pacgate
npm exec qm -- up

# ■■ qm
npm exec qm -- down
```

更新到新版本

```
cd C:\pacgate-ai-pr\deploy\client-bundle
.\install.ps1 -Update
```

-Update 现在会自动完成以下全部工作，因此不再需要单独执行 git pull（那一步最容易被遗忘，而一旦遗忘，就会让新镜像配上旧配置静默运行）：

步骤	作用
1	刷新仓库工作区（仅快进 fast-forward）
2	从模板重新渲染 MCP 配置，变更前先备份
3	拉取新的 GHCR 镜像
4	重启技术栈，并重载 nginx

当机器上存在本地改动时，它会拒绝执行而不是猜测：

- 仓库有未提交改动 → 跳过仓库更新，并列出生被改动的文件。不会 stash、reset 或丢弃任何内容。
- 存在远端没有的本地提交 → 不合并、不变基。仓库保持原样，其余更新继续进行。

如需仅更新镜像，可使用 -SkipRepoPull：

```
.\install.ps1 -Update -SkipRepoPull
```

qm 只做报告，不自动更新

如果本机运行了 qm，-Update 还会检查其沙箱镜像是否仍与源码一致：

```
[OK] qm sandbox matches its source (38e062ec7c5c...)
```

或

```
[WARN] qm sandbox source has CHANGED since the image was pinned.
qm is running OLD skills and tools. Rebuild + repin:
cd deploy\qm-pacgate
npm exec qm -- sandbox build # ■■■■■■■■ digest ■■■■
pwsh -File ..\..\scripts\qm-sandbox-fingerprint.ps1 -Write
```

这一点很重要：qm 的智能体运行在一个按 digest 固定的沙箱镜像里（记录在 `deploy/qm-pacgate/qm.config.jsonc`）。按 digest 固定本身是正确的 — 隔离边界 就应当不可变 — 但这意味着仓库更新可以改动

`deploy/qm-pacgate/sandbox/`，而镜像完全不变。于是智能体继续使用旧的 skills 和 tools 运行，任何地方都不会报错。

-Update 对此只报告、不自动重建，因为重建需要 Node 24 + npm + buildx，且之后必须重新固定 digest — 这属于配置变更，不应在客户机器上无人值守地执行。一次错误的自动重建，比一条可见的警告更糟。

更新会保留数据：- `./data/tenants/`（卷挂载）— 事项、文档、记忆 - Postgres 数据（命名卷）— 元数据数据库

这台机器是不是最新版本？直接问它

```
curl.exe -s http://localhost:8089/version
```

```
{"version":"<release>","revision":"<git sha>"}
```

这里返回的是编译进正在运行的 pacgate-api 二进制文件的版本，以及它所基于的 commit。它故意不回显 compose 中的 pin 或镜像 tag：那些记录的是“曾部署了什么”，而真正要捕获的故障，恰恰是所部署的产物与实际运行的进程不一致。

在此之前，无法区分一台最新机器和一台落后的机器 — 从外部看两者完全相同，唯一的办法是 SSH 进去读 compose 文件，并寄希望于容器与之相符。

切换模型

deer-flow（研究工作空间）：1. 编辑 `deer-flow-config.yaml` — 重新排序 models 列表（第一项 = 默认）2. 重启：`docker compose -f compose.prod.yaml restart deer-flow`

qm（协作工作空间）：1. 编辑 `qm-pacgate/qm.config.jsonc` — 更改 MODEL_NAME 2. 重启：`cd qm-pacgate && npm exec qm -- down && npm exec qm -- up`

注册新用户

`/api/auth/register` 仅限首位用户，引导账号创建后一律返回 403（见 Stage 3）。

此后的每个账号通过管理员路由创建：

```
# /pacgate ■■■■■—■ Stage 3 ■■■■■Bearer = ■■■■■■
# (■ POST /pacgate/api/auth/login ■■■■■ Stage 3 ■■■■■)
$body = @{"email"<user>@pacgate-law.com"; password="<password>"} | ConvertTo-Json
Invoke-RestMethod -Uri "http://localhost:8089/pacgate/api/auth/users" -Method Post `
  -Headers @{Authorization="Bearer <admin-token>"} -Body $body -ContentType "application/json"
```

备份数据库

```
docker exec pacgate-db pg_dump -U pacgate pacgate > backup.sql
```

查看日志

```
docker compose -f compose.prod.yaml logs -f pacgate-api
docker compose -f compose.prod.yaml logs -f deer-flow
```

已知限制

- QM 本地模型路由不可持久。为了让 QM 聊天针对本地 Ollama 工作，在 QM 核心的 `src/model/pi-models.ts`（容器可写层）中添加了一个自定义模型条目（`glm-5.3-flash:cloud`）。每当核心容器被重建时，此编辑都会丢失（例如 `qm down` 后的 `qm up`，或手动 `docker rm -f qm-pacgate-core`）。任何重建后，`glm-5.3-flash:cloud` 会从 `GET /v1/surface-config` → `webuiModels` 中消失，聊天轮次返回 403 "that model isn't available"。要重新应用：`bash # 1. ■ /app/src/model/pi-models.ts ■ MODEL_REGISTRY`

```
##### # { id: "glm-5.3-flash:cloud", name: "GLM 5.3 Flash (Ollama)",
fastMode: false, # webui: true, base: true, # custom: { template:
"gpt-4.1-mini", baseUrl: "http://host.docker.internal:11434/v1" } } # 2. ##
ModelEntry##### custom:{template,baseUrl}##### resolveModel() ##### # 3.
##### OPENAI_API_KEY=ollama-local#####Ollama ##### # 4. #####
```

要获得持久修复，请将更改提交到 qm 源码仓库并重建镜像，或搭建一个代理（例如 LiteLLM）将 openai 提供方映射到 Ollama。

- 每台机器都有自己的独立 Postgres 和 `./data/tenants/` 目录。除非你之后添加私有网格和同步或单一权威模型，否则事项数据不会在机器之间共享。
- PkuLaw 连接器令牌已过期。在 <https://mcp.pkulaw.com> 重新生成，并在试点期间需要中国法律搜索时在 `.env` 中设置 `PKULAW_API_KEY`。
- 四个 WASM crate（citation-check、clause-parser、doc-validator、rule-engine）仍是桩。这些是未来蓝图工作，不影响 Phase 1 试点功能。
- 模型选择：API 默认使用目标机器上可能不存在的模型。Stage 3 之后，应用按租户的模型覆盖，使 LLM 层级指向该机器 `ollama list` 中实际存在的模型。推荐的试点集（2026-08-28 基准测试）：`gemma4:12b-it-qat`（Main — 13 秒/工具轮，模式有效的工具调用，端到端验证）、`qwen3.8:27b-mtp-q4_K_M`（Mid — 73 秒/工具轮，批量表格审查质量更强）、`nomic-embed-text:latest`（嵌入）。交互层级避免使用推理模式模型（例如 nemotron）——它们可能挂起长 docx 生成。SQL 模板见 `plans/007-aipc-full-installation-handoff.md` 附录 A。

引用的文件

文件	用途
deploy/client-bundle/compose.prod.yaml	pacgate-api + deer-flow + Postgres + nginx 的 Docker Compose
deploy/client-bundle/install.ps1	核心栈的一键 Windows 安装程序
deploy/client-bundle/setup-qm.ps1	qm 引导脚本（密钥、配置、沙箱构建）
deploy/client-bundle/.env.example	客户端密钥模板
deploy/client-bundle/ollama-models.txt	要预拉取的模型
deploy/client-bundle/deer-flow-config.yaml	deer-flow 多模型配置（5 个模型，可切换）
deploy/qm-pacgate/qm.config.jsonc	qm 本地部署配置
deploy/SETUP-AND-OPERATIONS.md	完整的 3 天现场安装指南（参考）
deploy/DEPLOYMENT-GUIDE.md	工程师级部署细节（参考）