

qm + OpenViking + pacgate-ai 网关/RAG 集成手册

面向律师事务所技术团队与运维工程师 版本 0.2.0 — 2026-10-05 (Pacgate-ai v0.1.23) 中文版 (PDF 见 ./pdf/)

1. 手册说明

本手册面向需要部署、运维与理解 qm（协作工作空间）+ OpenViking（长期记忆）+ pacgate-ai 网关/RAG（法律元数据与向量检索）的技术团队。


它回答三个问题：

1. qm 如何与 pacgate-ai 网关/RAG 协同？—— 架构与数据流
2. 每个组件做什么？—— 功能与职责
3. 如何部署与排障？—— 安装步骤与常见问题

红线：本系统中的所有 AI 输出均为律师复核前的草稿，绝不构成最终法律意见，也绝不静默捏造事实。这一原则贯穿全部组件。

2. 系统架构

2.1 数据流



qm + OpenViking + pacgate-ai 网关/RAG 架构图

2.2 组件职责

组件	端口	职责	实现
qm portal	8181	前端门户：登录入口，代理到 web-ui/admin	ghcr.io/yc-software/qm/portal
qm web-ui	8182	协作界面：会话、文件、审批	ghcr.io/yc-software/qm/web-ui
qm admin	8183	管理控制台：用户、资源、审计	ghcr.io/yc-software/qm/admin
qm core	8180	协作引擎：运行编排、pi harness、审批	ghcr.io/yc-software/qm/core
qm auth	内部	认证代理（SMTP 登录链接；试点经 Mailpit，生产可配 Resend）	ghcr.io/yc-software/qm/auth
OpenViking	1933	长期记忆：结构化记忆、语义检索	ghcr.io/volcengine/openviking
pacgate-api	8080	法律元数据：案件、文档、工作流、RAG	ghcr.io/jzkk720/pacgate-api:0.1.23 (Rust)
pacgate-nginx	8089	统一入口，/pacgate/ 前缀	nginx:1.27-alpine
Ollama	11434	本地/云路由模型 + embedding	Windows 原生

2.3 登录与访问（客户交接）

以下地址为本机（localhost）访问入口。若通过远程访问，将 localhost 替换为该 AIPC 的局域网/公网地址。

访问入口	地址	用途
qm 门户（登录入口）	http://localhost:8181	律师登录入口（portal），登录后代理到 web-ui/admin
qm 协作界面	http://localhost:8182	会话、文件、审批（web-ui）
qm 管理控制台	http://localhost:8183	用户、资源、审计（admin）
qm 邮件捕手（登录链接）	http://localhost:8025	接收登录魔链（Mailpit），用于开发/测试环境
OpenViking 记忆	http://localhost:1933	长期记忆服务（MCP），由 AI 调用
pacgate-api 元数据	http://localhost:8089/pacgate/	机器对机器，由 pacgate-qm 工具调用

管理员账号：- qm 的管理员邮箱来自部署时的 ADMIN_GRANTS/AUTH_ALLOWED_EMAILS 设置（试点机当前使用 admin@pacgate-law.com，见 deploy/client-bundle/qm-pacgate/.env，以实际配置为准）。- 登录方式：qm 使用一次性登录魔链（magic-link）。在门户 http://localhost:8181 输入管理员邮箱，系统发送登录链接；开发/测试环境下该链接发送到 Mailpit（http://localhost:8025），在发起登录的同一浏览器中打开链接并确认。- 重置管理员：若 admin_grants 表为空（登录提示 "This deployment isn't set up yet"），向数据库种入管理员（见第 7.1 节）。

⚠️ 安全提示：PACGATE_API_PASSWORD、OPENVIKING_ROOT_API_KEY、CORE_SIGNING_SECRET 等为每台机器独立生成的密钥，仅保存在该机的

.env (gitignored)。交接时请通过安全渠道传递，不要写入本手册。

3. qm：协作工作空间

3.1 它是什么

qm 是 Pacgate-ai 的协作工作空间。律师在浏览器中打开它，进行团队配合：共享文件、审批 workflow、分派任务、跟踪审批。它通过 `qm up` 独立运行（无 Docker 镜像），使用 pi harness 编排 AI 运行。

3.2 关键技术点

- 无 Docker 镜像：qm 通过 `deploy/qm-pacgate/` 目录里的 `qm up` 运行。
- harness：默认使用 pi (`HARNESS=pi`)。pi harness 是进程内运行 (`src/harness/pi-harness.ts`)，无需额外安装。
- 模型：PI_MODEL 指定模型 ID。glm-5.3-flash:cloud 是自定义注册项，路由到 Ollama (`http://host.docker.internal:11434/v1`)。

3.3 模型配置 (qm.config.jsonc)

```
"env": {
  "core": {
    "HARNESS": "pi",
    "SANDBOX_BACKEND": "local",
    "MODEL_BASE_URL": "http://host.docker.internal:11434/v1",
    "PI_MODEL": "glm-5.3-flash:cloud",
    "PI_DETECT_MODEL": "glm-5.3-flash:cloud",
    "PI_TITLE_MODEL": "glm-5.3-flash:cloud",
    "PI_JUDGE_MODEL": "glm-5.3-flash:cloud",
    "NODE_ENV": "development"
  }
}
```

为什么设置 PI_DETECT/TITLE/JUDGE_MODEL：qm 的辅助模型调用（安全屏、标题、判断）默认解析到 gpt-5.6-luna (provider=openai)，会打到真实 `api.openai.com` 并用假密钥 `ollama-local` 触发 401。设置这三个变量为 `glm-5.3-flash:cloud` 后，辅助调用路由到 Ollama。

3.4 沙箱与工具

qm 的沙箱层 (sandbox/) 暴露两个工具给 AI：

工具	说明
pacgate-qm	Pacgate 工作流发现、案件绑定、案件记忆、工作流执行
firecrawl-qm	网页抓取与内容提取

pacgate-qm CLI 支持的命令：

```
workflow-categories workflows workflow ensure-matter
memory-get memory-save execute-workflow
ov-remember ov-search ov-read
```

3.5 与 OpenViking 集成

qm 沙箱通过 pacgate-qm 的 `ov-remember/ov-search/ov-read` 命令访问 OpenViking 长期记忆：

- `ov-remember --content "<■■■>"`：存储持久记忆（异步提取为结构化记忆）
- `ov-search --query "<■■■■>"`：回忆相关记忆、资源与技能

- `ov-read --uri "viking://user/default/memories/<path>"`：读取具体记忆文档

⚠ 密钥：`ov-*` 命令调用 OpenViking 的 `/mcp` 端点，该端点使用 root 密钥（`OPENVIKING_ROOT_API_KEY`）认证，不是应用密钥 `OPENVIKING_API_KEY`。若配置了应用密钥，`ov-search/ov-remember` 会返回 401 "Invalid API Key"。沙箱 `secretEnv` 需包含 `OPENVIKING_ROOT_API_KEY`（与 `client-bundle.env` 同值）。

红线：绝不通过 `ov-remember` 存储案件文件或保密案件材料——那些属于 Pacgate 案件存储。OpenViking 记忆仅用于会话上下文：决策、偏好与工作知识。

4. OpenViking：长期记忆通道

4.1 它是什么

OpenViking 是 Pacgate-ai 的长期记忆服务，把跨会话的决策、偏好与工作知识提取为结构化记忆，供 AI 在后续会话中语义检索、回忆与复用。

4.2 配置

```
{
  "server": { "host": "0.0.0.0", "port": 1933, "root_api_key": "<OPENVIKING_ROOT_API_KEY>" },
  "storage": { "workspace": "/app/.openviking/workspace" },
  "embedding": {
    "dense": {
      "provider": "ollama",
      "api_base": "http://host.docker.internal:11434/v1",
      "model": "nomic-embed-text",
      "dimension": 768
    }
  }
}
```

4.3 关键点

- 端口：1933（HTTP，对外暴露）
- embedding：Ollama 的 `nomic-embed-text`（768 维）
- `root_api_key`：⚠ 使用 `OPENVIKING_ROOT_API_KEY`，不是 `OPENVIKING_API_KEY`。

5. pacgate-ai 网关 / RAG（pacgate-api）

5.1 它是什么

`pacgate-api` 是 Pacgate-ai 的法律元数据网关（Rust 实现），管理租户、案件、文档、 workflow 模板，并提供 RAG（向量检索）与法律连接器检索。

5.2 服务表面

服务	端点	说明
认证	POST /api/auth/login	登录并返回 JWT
案件	GET /api/matters	列出案件
文档	GET /api/matters/:id/documents	某案件的文档
工作流	GET /api/workflows	列出工作流模板
工作流分类	GET /api/workflows/categories	工作流分类
工作流详情	GET /api/workflows/:id	单工作流步骤

服务	端点	说明
RAG	GET /api/kb/search	内部按案件向量检索
连接器	GET /api/search	外部法律数据库检索
连接器列表	GET /api/search/connectors	可用法律数据源

5.3 RAG（向量检索）

pacgate-api 的 RAG 存储使用 Ollama 的 `nomic-embed-text` 作为 embedding 模型，支持按案件（`matter_id`）的向量检索，并支持数据分级（`max_data_level`）。这使 AI 能够带引用出处地回答法律问题，而不必上传文件。

5.4 工作流模板

pacgate-api 的 `GET /api/workflows` 暴露 222 个法律工作流模板（46 类，含上述 10 类经典示例）。可用 `?category=&search=` 过滤：

分类	工作流	步骤数
contract_review	Contract Review（合同审查）	3
contract_review	Contract Comparison（合同比对）	2
due_diligence	Due Diligence Review（尽调审查）	3
legal_research	Legal Research Memo（法律检索备忘录）	3
tabular_review	Tabular Document Review（表格化文档审查）	3
document_generation	Contract Drafting（合同起草）	2
document_generation	Legal Opinion（法律意见书）	2
compliance	Compliance Check（合规检查）	3
ma	SPA Review（股权收购协议审查）	3
litigation	Discovery Review（证据开示审查）	3

5.5 pacgate-qm 桥

qm 沙箱中的 `pacgate-qm` CLI 调用 `pacgate-api`（经 `nginx /pacgate/` 前缀）。它用 `PACGATE_API_EMAIL/PACGATE_API_PASSWORD` 认证，支持：

⚠ URL：`qm.config.jsonc` 沙箱环境中的 `PACGATE_API_URL` 必须包含 `/pacgate` 前缀（如 `http://host.docker.internal:8089/pacgate`）。若省略该前缀，登录 POST 直达 `/api/auth/login` 会触发 `pacgate-api` 的 CSRF 校验并返回 403。

- 工作流发现：`workflow-categories`、`workflows`、`workflow <id>`
- 案件绑定：`ensure-matter --org-id <org> --channel-id <channel>`
- 案件记忆：`memory-get`、`memory-save --memory-json '{"key":"value"}'`
- 工作流执行：`execute-workflow --workflow-id <id> --org-id <org> --channel-id <channel>`

红线：绝不捏造工作流 ID、案件 ID 或 Pacgate 作用域绑定。先查询，或提供真实的 QM 作用域标识符。

6. 部署

6.1 前置条件

- Docker Desktop (WSL2 后端)
- Ollama (Windows 原生) 已拉取 `glm-5.3-flash:cloud`、`nomic-embed-text` 等模型
- Node.js 24+ (供 qm 使用)
- `deploy/qm-pacgate/` 目录与 `qm.config.jsonc`

6.2 qm 部署

```
cd deploy/qm-pacgate  
npm ci # █ npm install  
npm exec qm -- check # ██████  
npm exec qm -- sandbox build # ████████████████  
npm exec qm -- up # ████████████████████
```

⚠ `qm up` 是破坏性的：它会 `docker rm -f` 所有服务并重新运行，注入 `.env` 中的密钥。这会把两处手工修复还原：1. `pi-models.ts` 的 `glm-5.3-flash:cloud` 条目（在容器可写层），需 `docker cp` 重新应用。2. `dev` 模式认证（若设置了 `CORE_SIGNING_SECRET` 会强制 `portal` 模式，登录失效）。

6.3 验证

```
# ■■■■■■
docker ps | Select-String 'qm-pacgate'

# ■■■■■■■■■■
docker logs qm-pacgate-core --since 5m | Select-String 'listening'

# pacgate-api ■■■■■■ nginx■
$env:PACGATE_API_URL='http://localhost:8089/pacgate'
$env:PACGATE_API_EMAIL='qm-bridge@pacgate.local'
$env:PACGATE_API_PASSWORD='<password>'
python deploy/qm-pacgate/sandbox/tools/pacgate-qm/pacgate_qm.py workflow-categories
```

7. 排障（常见问题）

7.1 登录：portal 显示 "This deployment isn't set up yet"

症状：portal 显示"未设置"，无法进入管理控制台。 根因：core 的 modelProviderConfigured:false；且 admin_grants 表为空，无人是 admin，/admin 403。
修复：向 admin_grants 表种入管理员：

```
docker exec qm-pacgate-pg psql -U postgres -d qm -c "INSERT INTO admin_grants (principal_id, scope_id, role,
```

7.2 登录：魔链 "This sign-in link no longer works"

症状：打开邮箱里的登录链接报"链接失效"。根因：魔链是单次使用且绑定浏览器——JWT **state** 声明必须匹配发起流程的浏览器 OAuth **state** cookie。在另一个浏览器/配置文件打开或重复使用已用过的链接会报错。

修复：在发起登录的同一个浏览器中打开链接，点击确认。

7.3 模型 401 "Incorrect API key"

症状：ollama-local 被当作真实 API 密钥，请求打到真实 api.openai.com。根因：辅助模型解析到 gpt-5.6-luna (provider=openai)，或主模型选成 gpt-5.6-sol。修复：- 设置 PI_DETECT_MODEL/PI_TITLE_MODEL/PI_JUDGE_MODEL = glm-5.3-flash:cloud (辅助调用) - 通过管理 API 将 org 基础模型设为 glm-5.3-flash:cloud：

```
PUT /admin/api/scopes/org:pacgate/base-model body: {"modelId":"glm-5.3-flash:cloud"}
```

7.4 沙箱：报 "requires a running Docker daemon"

症状：SANDBOX_BACKEND=local 时报"需要运行中的 Docker daemon"，但 Docker 明明在运行。根因：qm core 在容器内部运行 docker CLI，需要挂载宿主的 docker.sock 与 docker CLI。修复（已在 deploy/qm-pacgate/compose.qm.yaml 完成）：core 现已挂载 ./patch/docker-cli/docker:/usr/local/bin/docker:ro 与 /var/run/docker.sock，并将 ./patch/local-sandbox.ts 只读挂载到 /app/src/sandbox/local-sandbox.ts。该补丁让沙箱经容器 IP (docker inspect 解析) 直连 exec daemon——修复了旧的 127.0.0.1:<hostport> 回环死路，并会把 FLY_RESIDENT_ENV_* 前缀变量经 docker run -e 透传 (PACGATE_API_URL 由此进入沙箱)。

7.5 沙箱镜像不存在

症状：local sandbox image ... not found。根因：旧配置固定在 localhost:5000 registry，该地址不可达（已废弃，见 deploy/DEFECT-qm-sandbox-image-unobtainable.md）。修复（已完成）：qm.config.jsonc 的 sandbox 镜像现固定为 ghcr.io/jzkk720/pacgate-sandboxes@sha256:52e867fc...（公开可拉取）。如需重建，仍可运行 npm exec qm -- sandbox build && npm exec qm -- sandbox publish。

8. 安全与隐私

- 数据边界：案件文件、检索历史保存在本机 AI 计算机上；对话文本经由已启用的 AI 模型服务处理，文件本身绝不上传。
- 凭据：PACGATE_API_EMAIL/PACGATE_API_PASSWORD、OPENVIKING_ROOT_API_KEY 等存于 .env (gitignored)。不要提交到仓库。
- 红线：AI 输出均为律师复核前的草稿，绝不构成最终法律意见。

本手册由 pacgate-ai 部署文档与运行环境自动整理生成。版本 0.2.0 — 2026-10-05 (Pacgate-ai v0.1.23)。